

ROTATION-INVARIANT METHODS FOR OBJECT RE-IDENTIFICATION

Adrián Cerezuela Hernández

Director: Ramon Morros Rubió

Co-director: Ignasi Nogueiras Marco

INTRODUCCIÓ

CONTEXT DEL PROJECTE

En col·laboracio amb el centre de recerca CEAB-CSIC

UPC + CEAB Centre d'Estudis Avançats de Blanes

Ignasi Nogueiras - Feb 2023

Computer vision for ant tracking

A tool for advancing collective behavior research

Marc Corretgé - Jun 2024

Tracking visual de formigues en un entorn controlat

Ant Tracking

Pol Serra - Gen 2024

RI Methods for Object Re-Identification

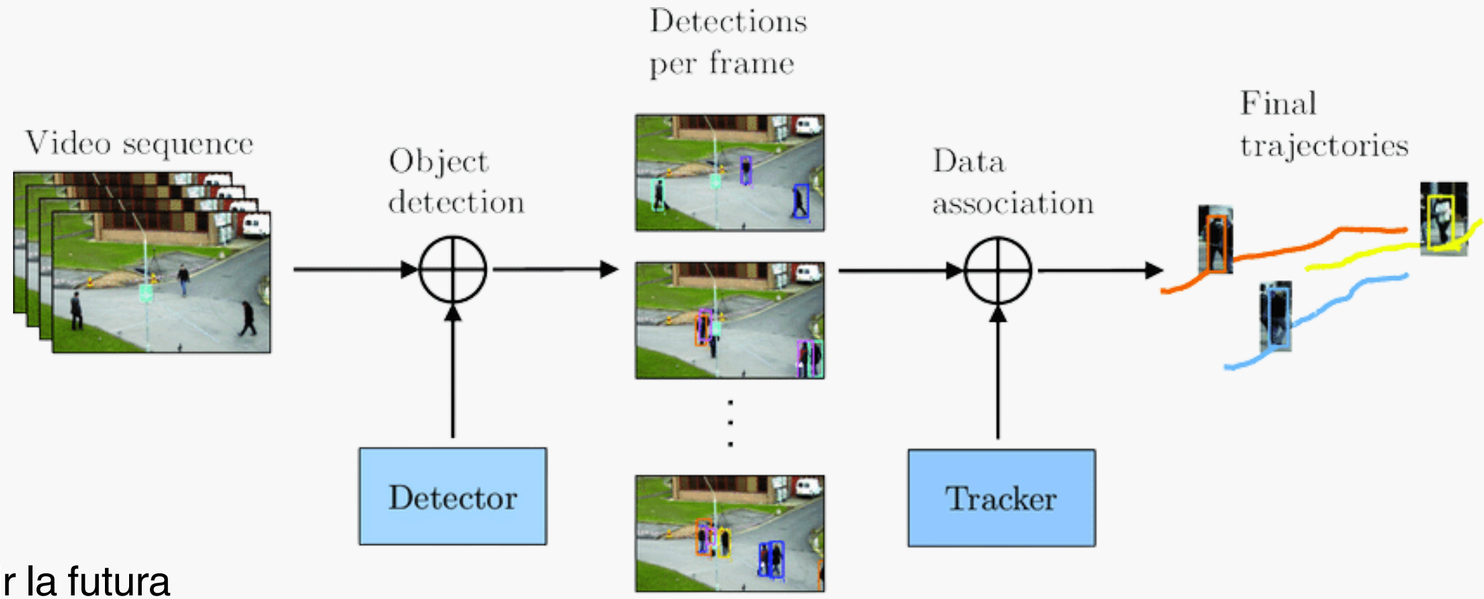
Adrián Cerezuela - Jun 2025

INTRODUCCIÓ

TRACKING: QUÈ ÉS I COM FUNCIONA

Definim el tracking com el procés de localitzar i seguir un o múltiples objectes especifics al llarg d'una seqüencia de vídeo

- Tracking-by-Query (TBQ)
- Tracking-by-Detection (TBD)



Source: L. Leal-Taixé, *Multiple object tracking with context awareness* , 2016

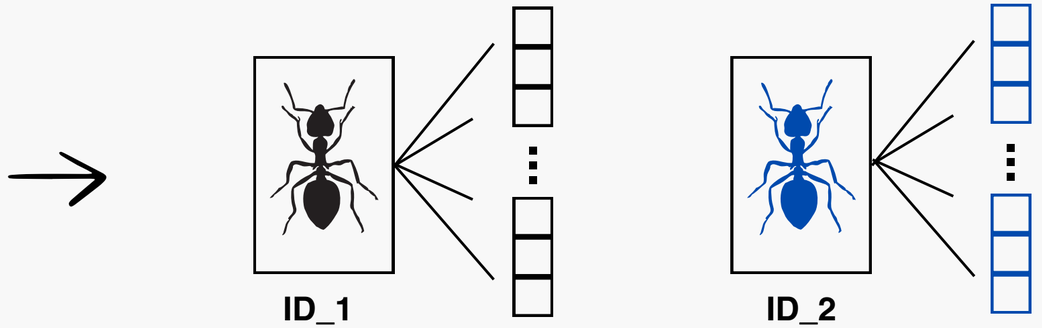
El pas d'associar IDs pot basar-se en

- Moviment – Filtre de Kalman per predir la futura posició de l'objecte

  Exemple: OC-SORT

- Aparença – Es basa en característiques visuals extretes dels objectes detectats per mantenir IDs consistents a través dels frames

  Exemple: StrongSORT



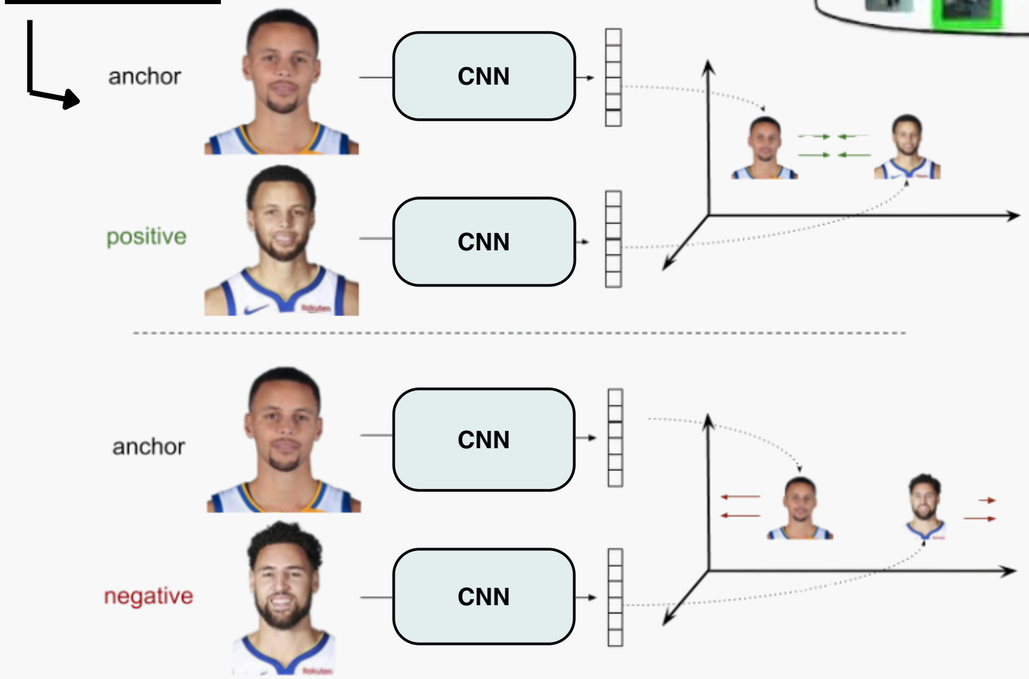
INTRODUCCIÓ

MODELS DE RE-IDENTIFICACIÓ

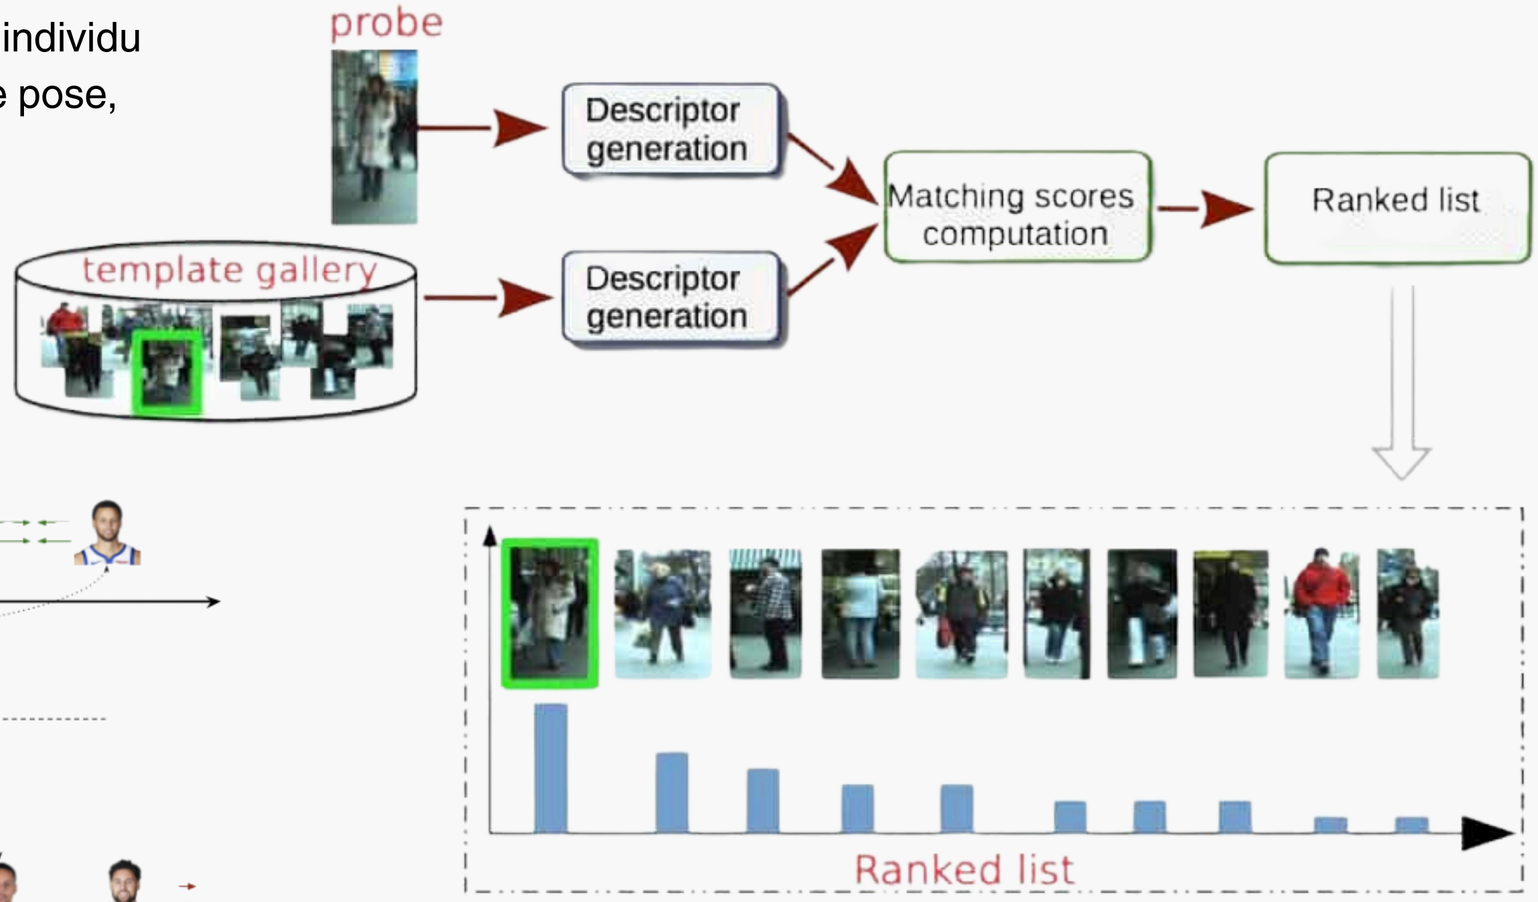
Objectiu: Aprendre les característiques d'un individu per saber-lo reconèixer en front de canvis de pose, il·luminació, perspectiva, oclusions...

Funcions de pèrdua

Triplet Loss + Classification Loss



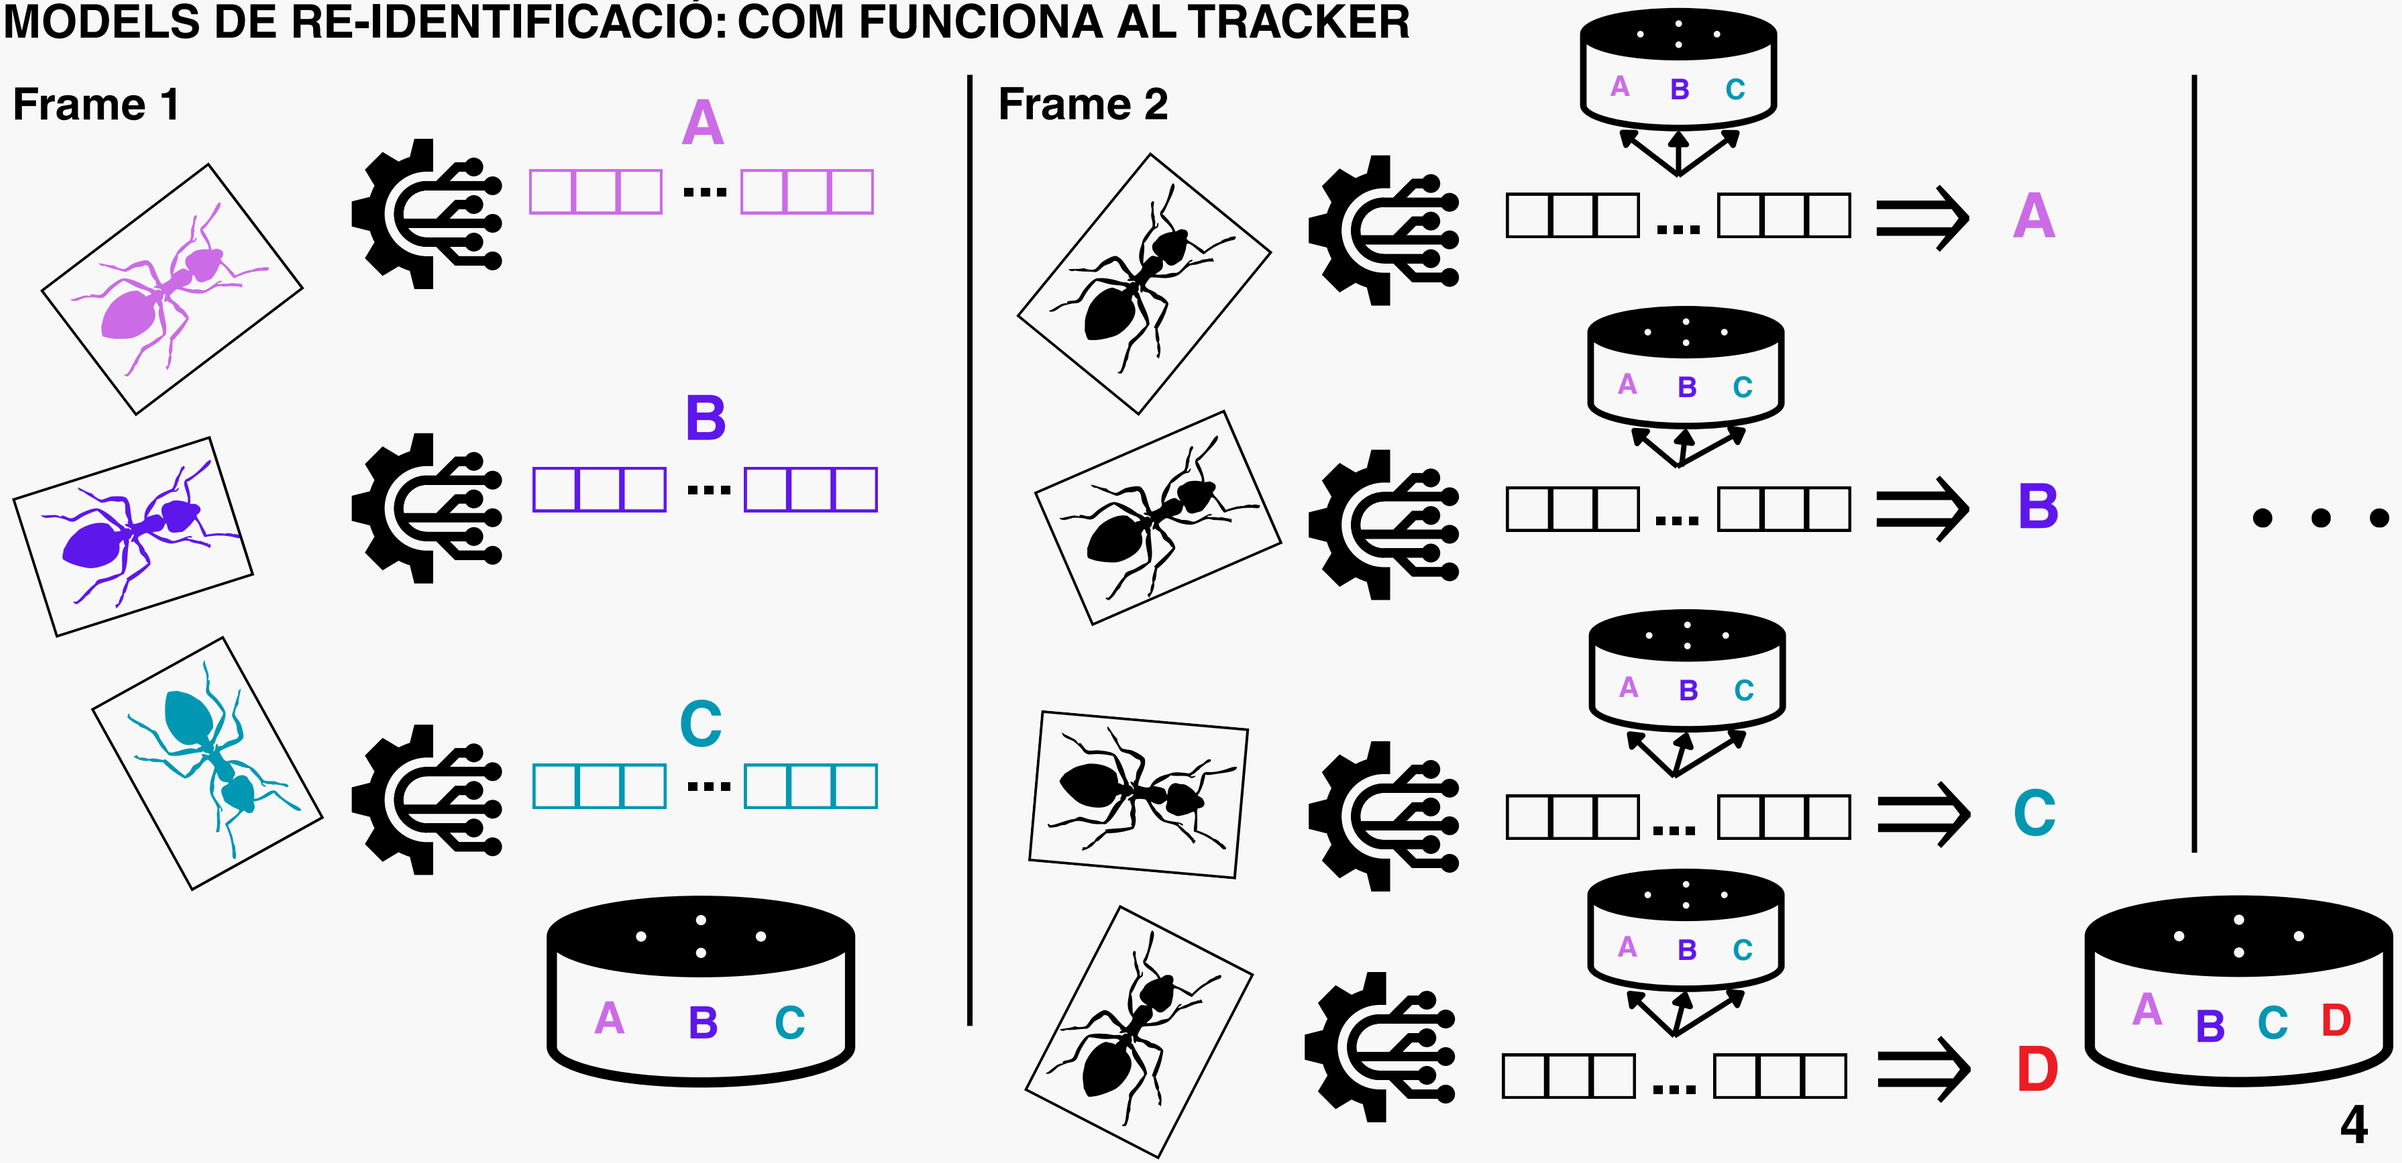
Source: R. Gómez, *Understanding Ranking Loss, Contrastive Loss, Margin Loss, Triplet Loss, Hinge Loss and all those confusing names,* 2019



Source: B. Lavi, I. Ullah, M. Fatan, and A. Rocha, *Survey on reliable deep learning-based person re-identification models: Are we there yet?,* 2020

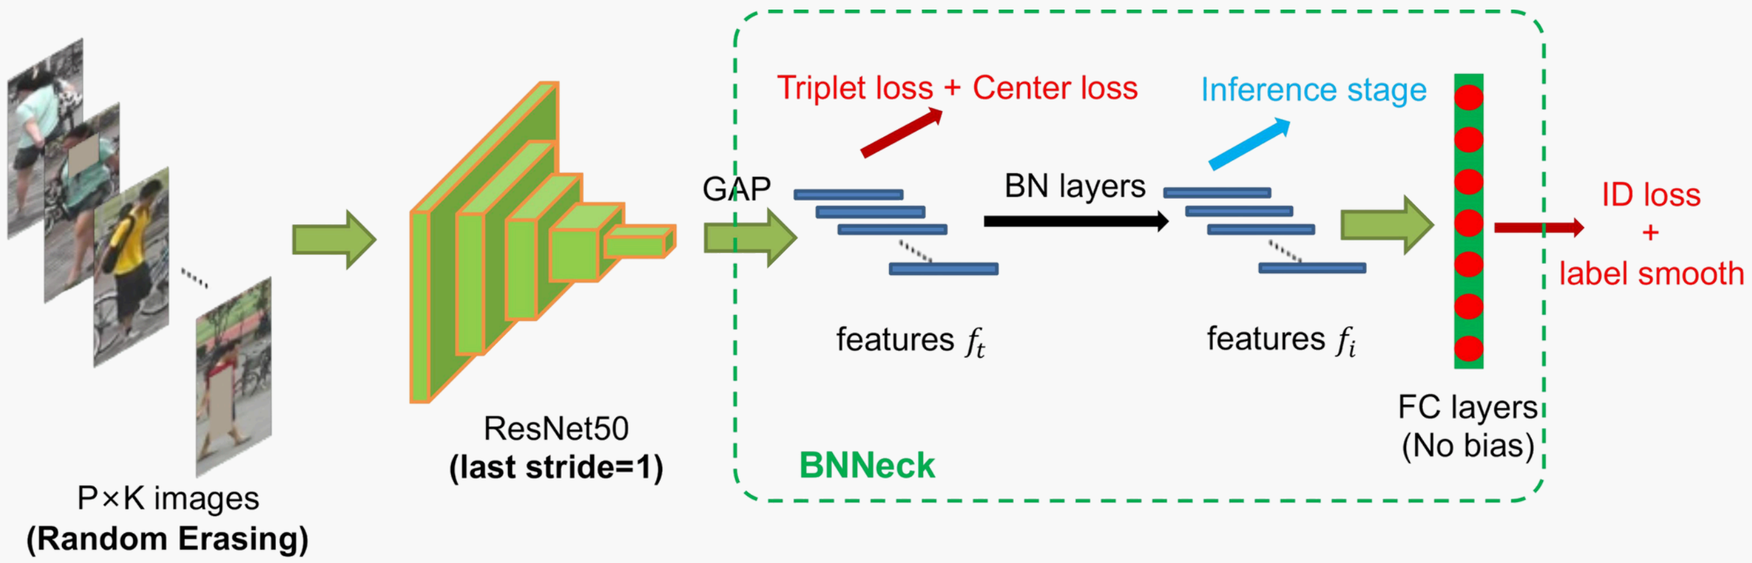
INTRODUCCIÓ

MODELS DE RE-IDENTIFICACIÓ: COM FUNCIONA AL TRACKER



MODEL

APARENÇA ALS TREBALLS PREVIS: BAG OF TRICKS



Source: H. Luo, Y. Gu, X.Liao, S.Lai, W.Jiang, *Bag of Tricks and A Strong Baseline for Deep Person Re-identification,* 2019

- Warmup Learning Rate
- Random Erasing Augmentation (REA)
- Label Smoothing
- Last Stride Adjustment
- Batch Normalization Neck
- Center Loss

MODEL

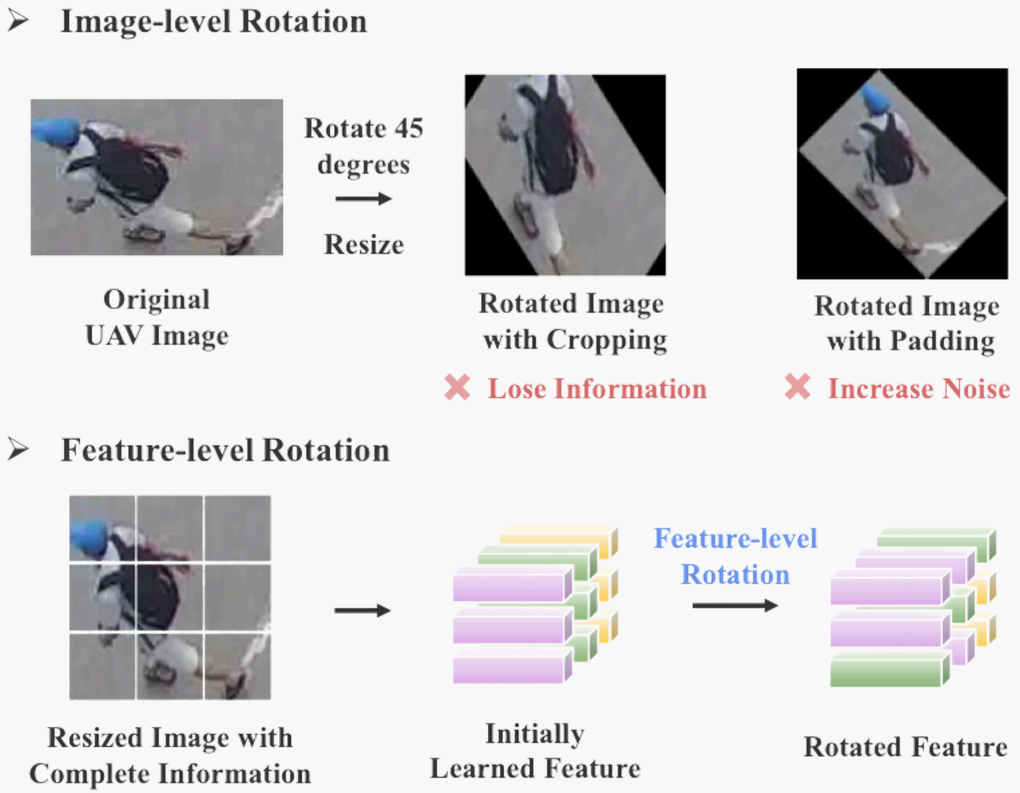
ROTTRANS: INTRODUCCIÓ

Objectiu: Forçar el model a aprendre una representació que sigui **invariant a la rotació**. El model ha d'entendre que una formiga és la mateixa independentment de la seva orientació



Per què RotTrans?

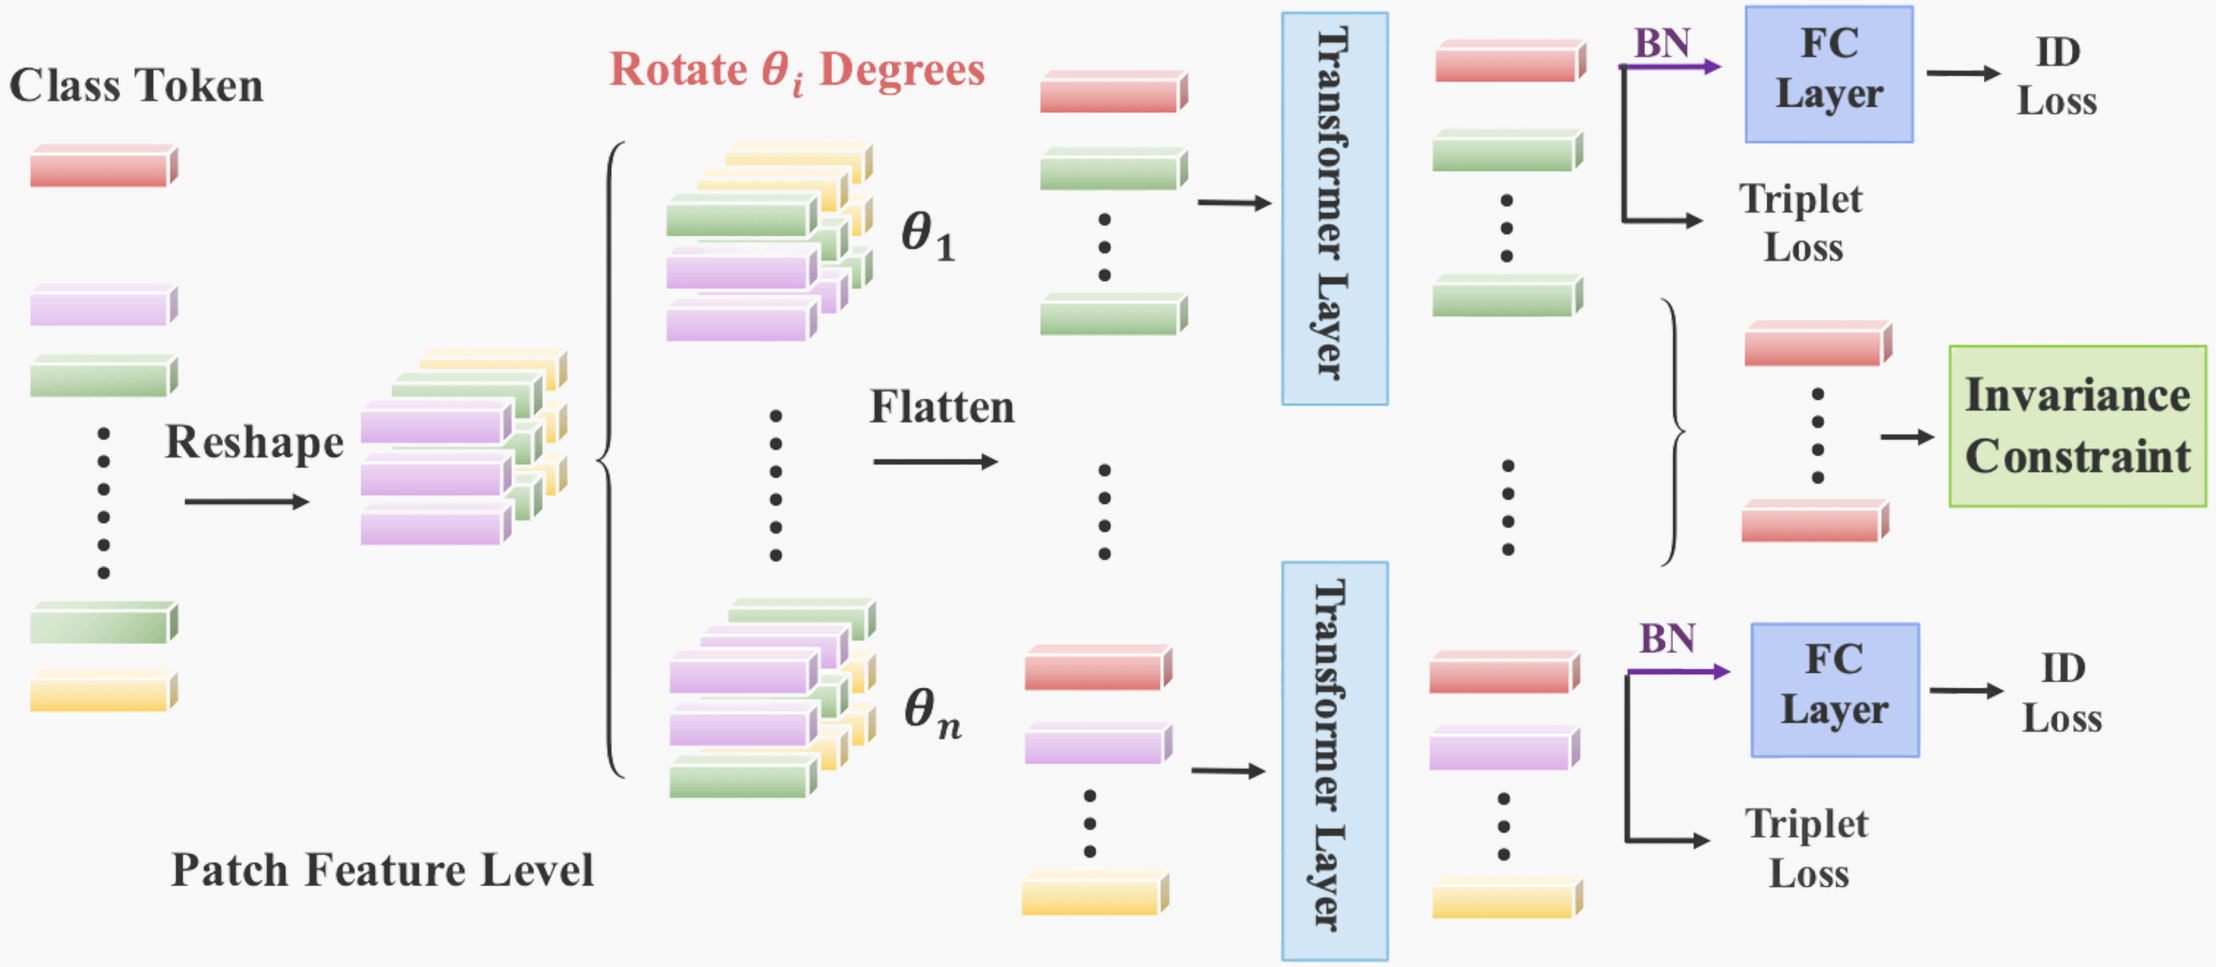
- És el model que millors resultats presenta amb una constraint d'invariància explícita, arribant a l'estat de l'art al dataset PRAI-1581.
- El dataset PRAI-1581 consta d'imatges de persones captades des d'una vista superior, igual que el nostre cas amb les formigues.



Source: S. Chen, M. Ye, and B. Du, *Rotation invariant transformer for recognizing object in UAVs*, 2023

MODEL

ROTTRANS: ARQUITECTURA



Source: S. Chen, M. Ye, and B. Du, *Rotation invariant transformer for recognizing object in UAVs*, 2023

DATASETS

NOU DATASET: OBTENCIÓ DELS CROPS

Video individual per a cada formiga - 1800 frames per ID

Detecció - YOLOv8 large adaptat per Oriented Bounding Boxes (OBB)

Videos processats frame per frame aplicant un threshold de 0.3







Annotacions en format **MOT Challenge**

< frame >, < –1 >, < bb left >, < bb top >, < bb width >, < bb height >, < conf >, < –1 >,< –1 >, < –1 >, < angle deg >

DATASETS

NOU DATASET: OBTENCIÓ DELS CROPS

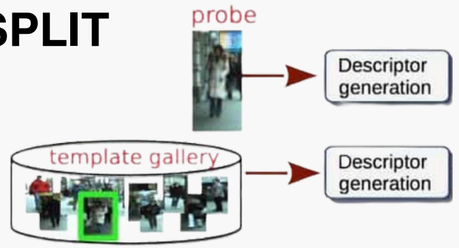


ID 000 003 004 005 008 010 011 012 013 014



ID 106 108 110 111 112 113 116 117 121 122

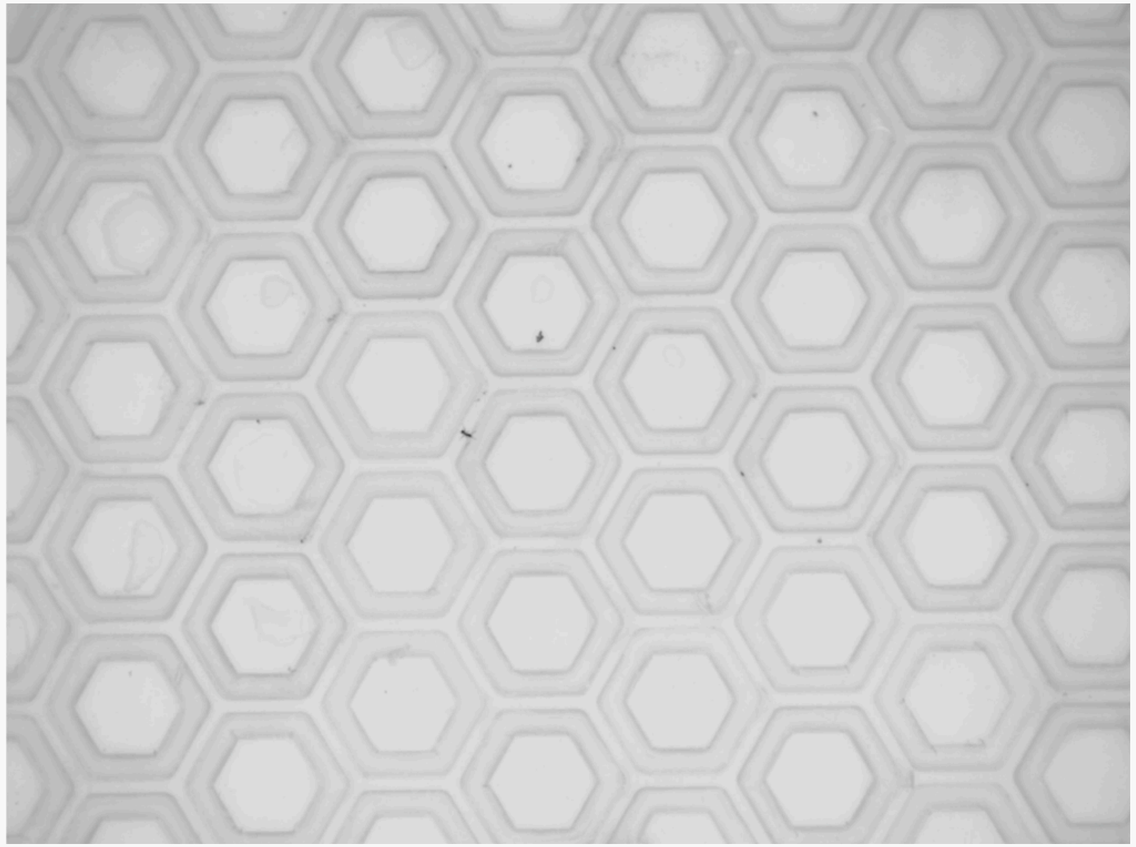
SPLIT



Set	Identities	Cameras	Images	Percentage
Training	63	1	113130	50.3%
Query	63	1	3150	1.4%
Gallery	63	1	108755	48.3%
Total	**126**	**1**	**225035**	**100.0%**

DATASETS

DATASET DE REFERÈNCIA: BASELINE DE PROJECTES PREVIS



Deteccions manuals → CVAT (Computer Vision Annotation Tool)

Treball exhaustiu de post-processing manual

Set	Identities	Cameras	Images	Percentage
Training	90	2	6730	51.7%
Query	67	2	489	3.8%
Gallery	86	2	5795	44.5%
Total	**176**	**2**	**13014**	**100.0%**



ID 002 003 004 005 010

● ● ●



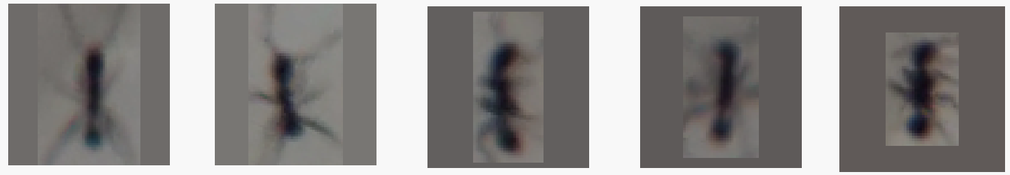
ID 174 175 180 183 186

DATASETS

TEST DATASET



Set	Identities	Cameras	Images	Percentage
Training	-	-	-	-
Query	10	1	1000	1.7%
Gallery	10	1	56350	98.3%
Total	**10**	**1**	**57350**	**100.0%**



ID 000 001 002 003 004

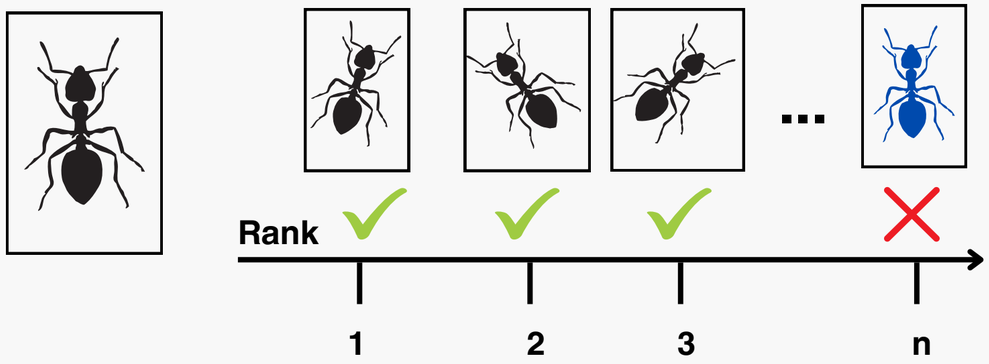


ID 005 006 007 008 009

MÈTRIQUES DE RE-IDENTIFICACIÓ

Escenari d'exemple: Tenim una imatge *query* i una galeria de candidats

Per la imatge *query* el model ordena les imatges de la galeria de més a menys semblant



1. Rank-k accuracy Hem trobat una coincidència correcta entre els *k* primers resultats?

$$\text{Rank-}k = \frac{1}{N}\sum_{i=1}^{N} 1\left(\text{rank}_i \leq k\right)$$

2. mAP (mean Average Precision)

Com de bona és la qualitat de tot el Ranking?

Després d'establir el Ranking, per a cada classe:

- Es calcula la Precisió per diferents nivells de Recall
- S'integra la corva Precision vs Recall → **AP_k**

De manera simplificada, el mAP es calcula com $$\text{mAP} = \frac{1}{N}\sum_{k=1}^{N} \text{AP}_k$$

RESULTATS

TRAINING: SETUP

Input size: [256,128] → Letterbox resizing per no perdre proporcions

Padding pixels: 10 Normalization: ImageNet channel means and std

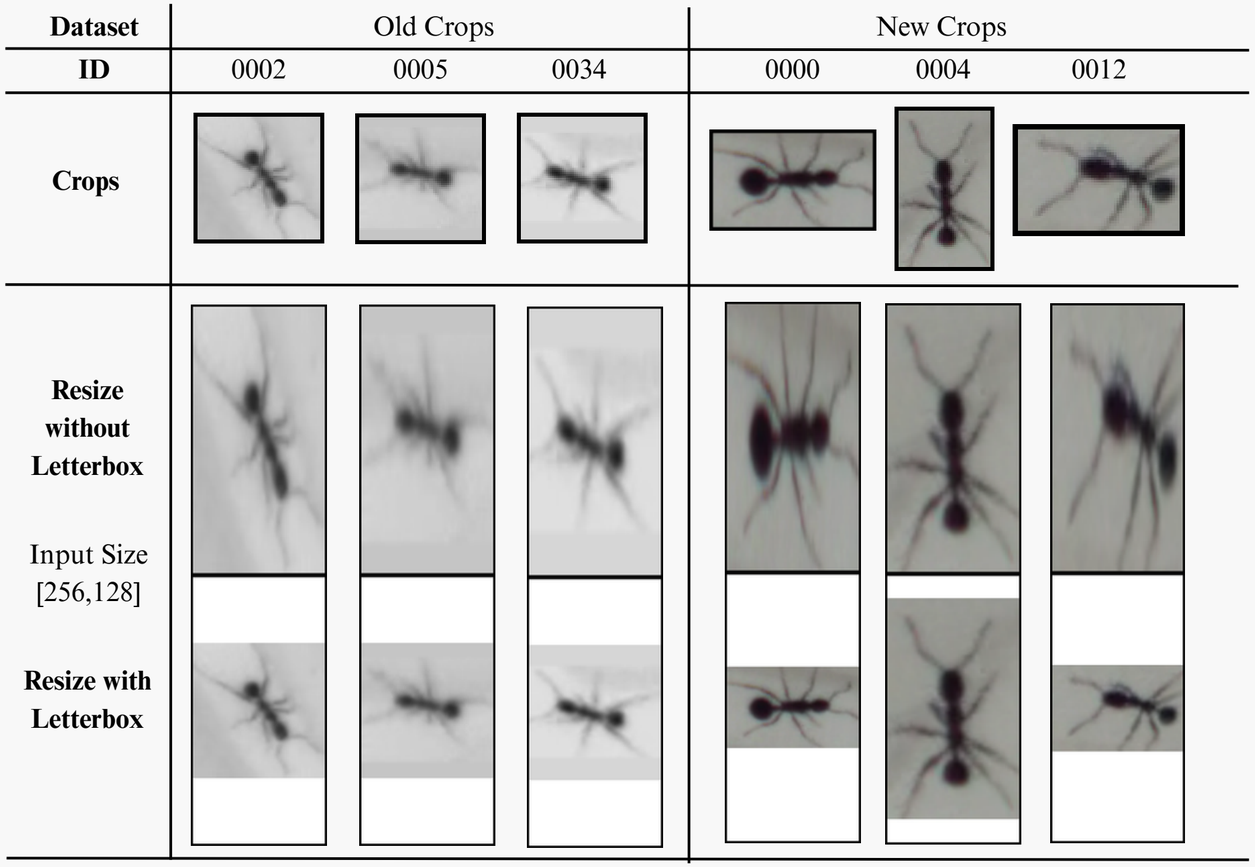
Random Crop Probability: 0.5 REA Probability: 0.5

Examples

Random Cropped Image Random Erased Image







RESULTATS

TRAINING: MÈTRIQUES DE VALIDACIÓ I ANÀLISI COMPARATIU

Dataset: Antic Dataset - Crops processats manualment

Nombre d'IDs: 176

Dues configuracions generals considerades

- RotTrans Paper → Detalls d'implementació
- BoT predeterminada utilitzada a anteriors projectes

Hiperparámetres introduits amb RotTrans

Nombre de rotacions (N): 4

Rang d'angles de rotació: [-15º, 15º]

Pes de les Original Features (λ) : 0.5

Pes de les Rotated Features (1 - λ) : 0.5

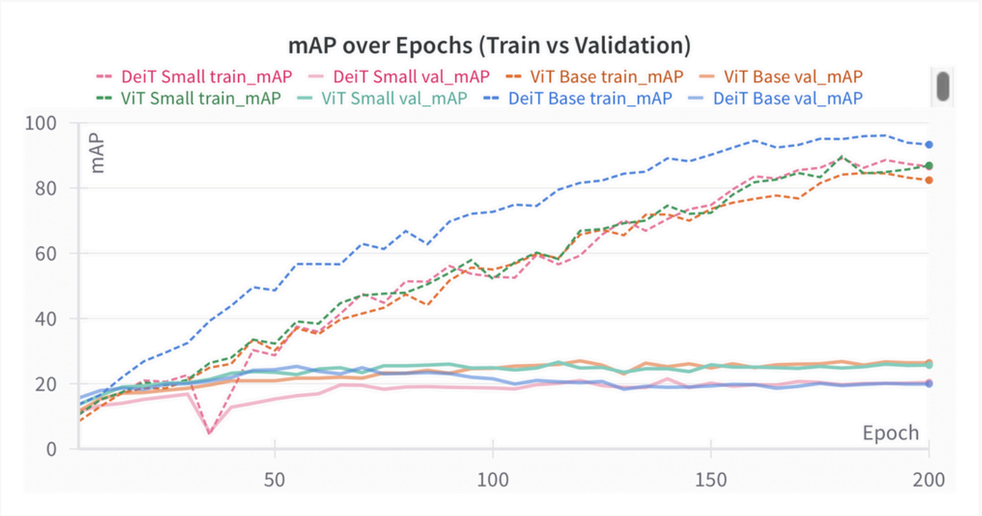
Resultats obtinguts

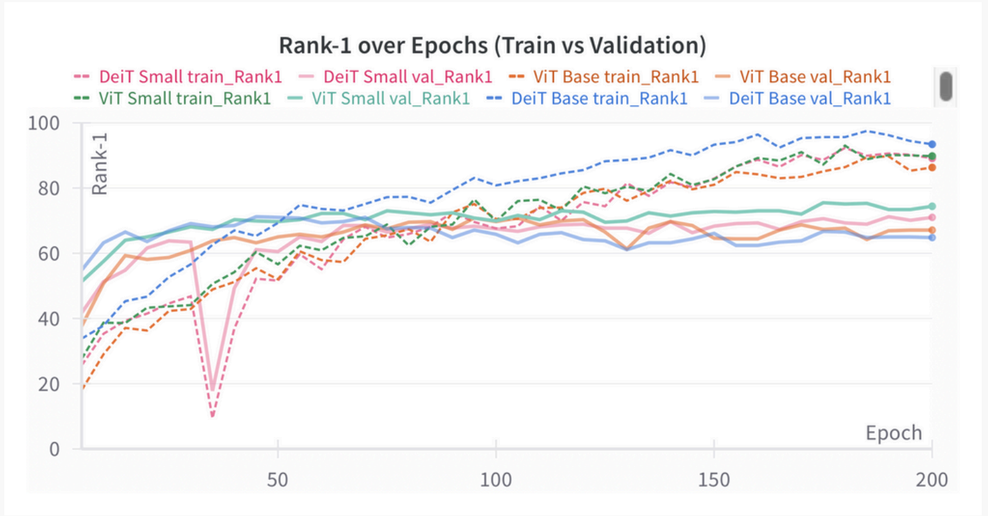
Model	*Backbone*	*Hyperparameter Config*	*Rank-1*	*Rank-5*	*mAP*	*Time*
BoT	**ResNet-50**	**Default Setup**	**72.6**	**87.3**	**28.6**	**00:20h**
BoT	ResNet-101	Default Setup	72.6	85.3	27.0	00:29h
RotTrans	Base ViT	Default Setup	67.3	82.0	21.3	01:58h
RotTrans	Base ViT	RotTrans Paper	70.3	86.3	27.0	03:57h
RotTrans	Base DeiT	RotTrans paper	70.8	86.3	25.3	03:51h
RotTrans	**Small-Patch ViT**	**RotTrans Paper**	**75.5**	**86.1**	**25.3**	**03:15h**
RotTrans	Small-Patch DeiT	RotTrans Paper	71.0	84.0	20.4	02:40h

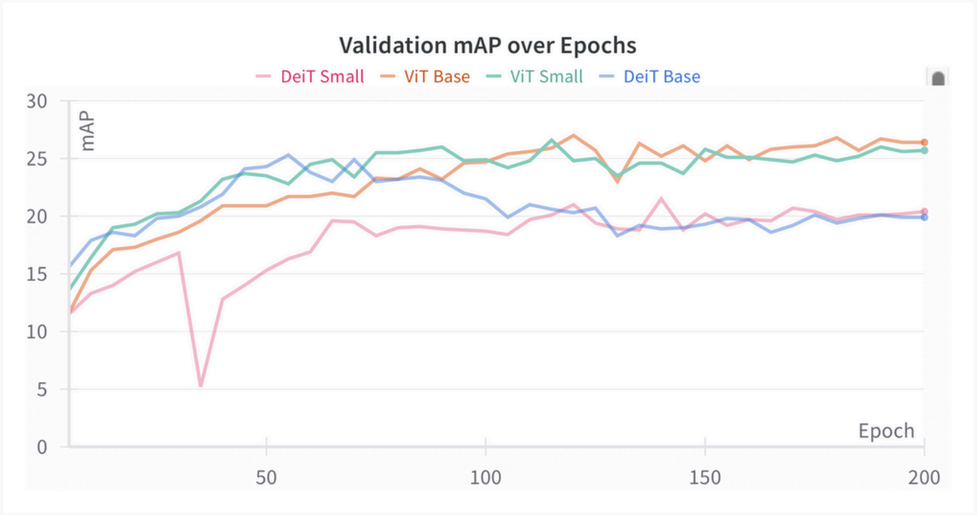
RESULTATS

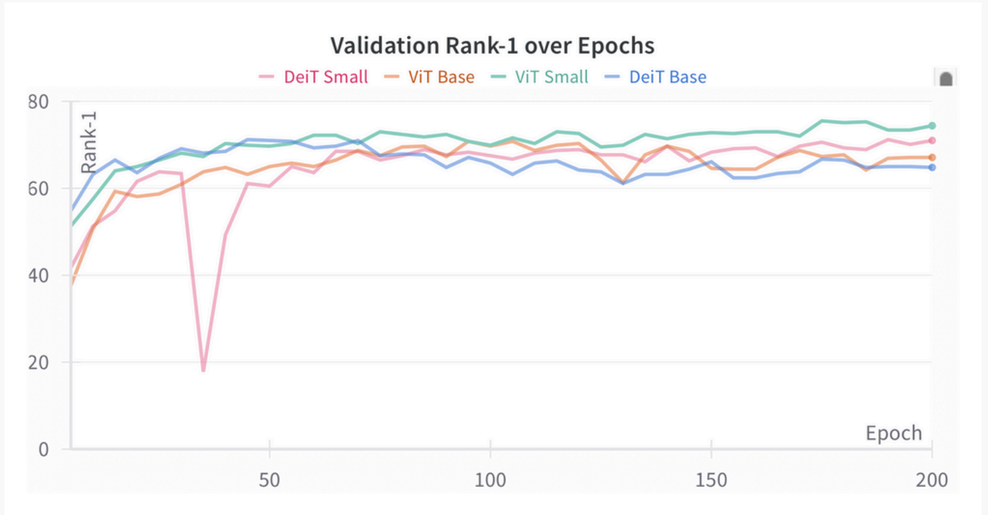
TRAINING: MÈTRIQUES DE VALIDACIÓ I ANÀLISI COMPARATIU

Dataset: Antic Dataset - Crops processats manualment
Nombre d'IDs: 176







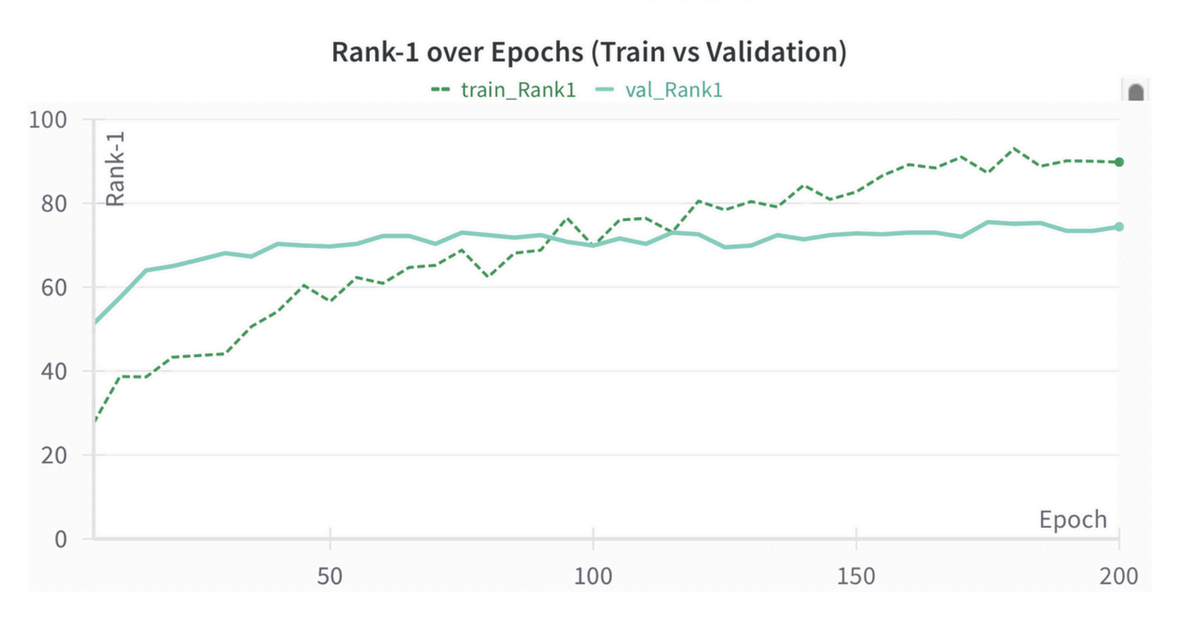


RESULTATS

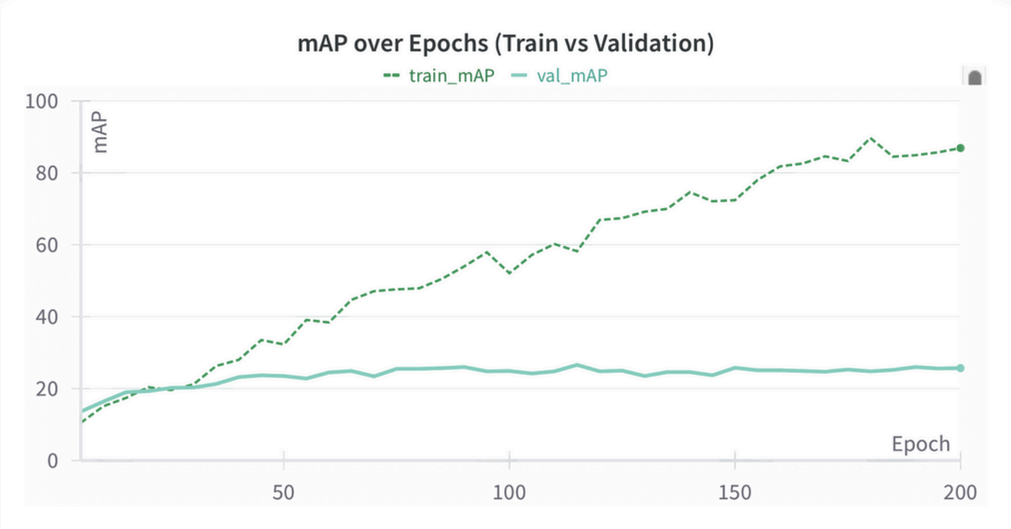
TRAINING: MÈTRIQUES DE VALIDACIÓ I ANÀLISI COMPARATIU

Dataset: Antic Dataset - Crops processats manualment
Nombre d'IDs: 176

Model	*Backbone*	*Hyperparameter Config*	*Rank-1*	*Rank-5*	*mAP*	*Time*
BoT	**ResNet-50**	**Default Setup**	**72.6**	**87.3**	**28.6**	**00:20h**
BoT	ResNet-101	Default Setup	72.6	85.3	27.0	00:29h
RotTrans	Base ViT	Default Setup	67.3	82.0	21.3	01:58h
RotTrans	Base ViT	RotTrans Paper	70.3	86.3	27.0	03:57h
RotTrans	Base DeiT	RotTrans paper	70.8	86.3	25.3	03:51h
RotTrans	**Small-Patch ViT**	**RotTrans Paper**	**75.5**	**86.1**	**25.3**	**03:15h**
RotTrans	Small-Patch DeiT	RotTrans Paper	71.0	84.0	20.4	02:40h







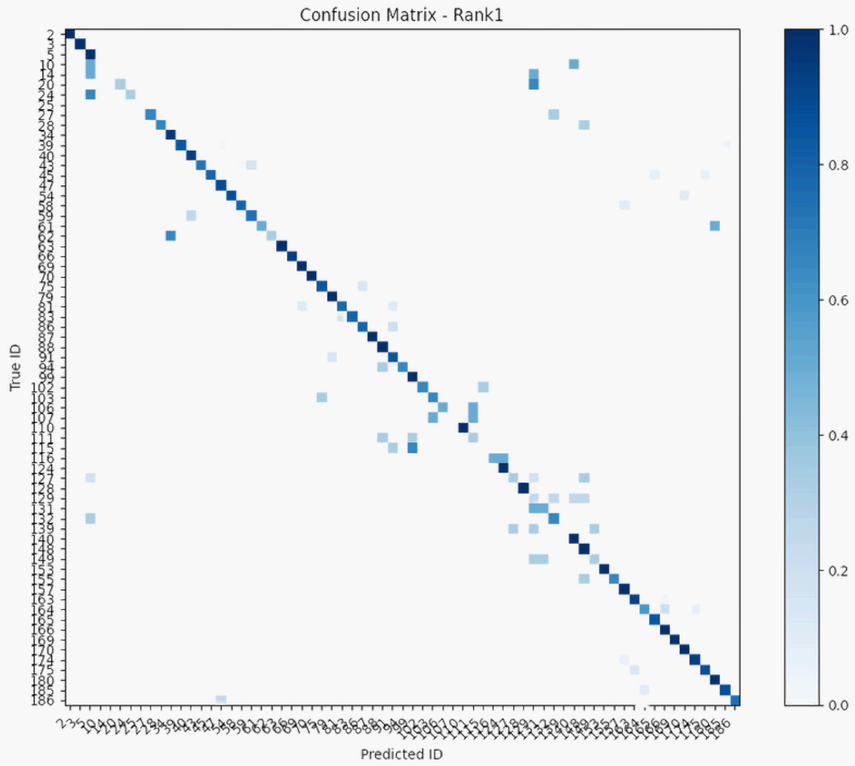
RESULTATS

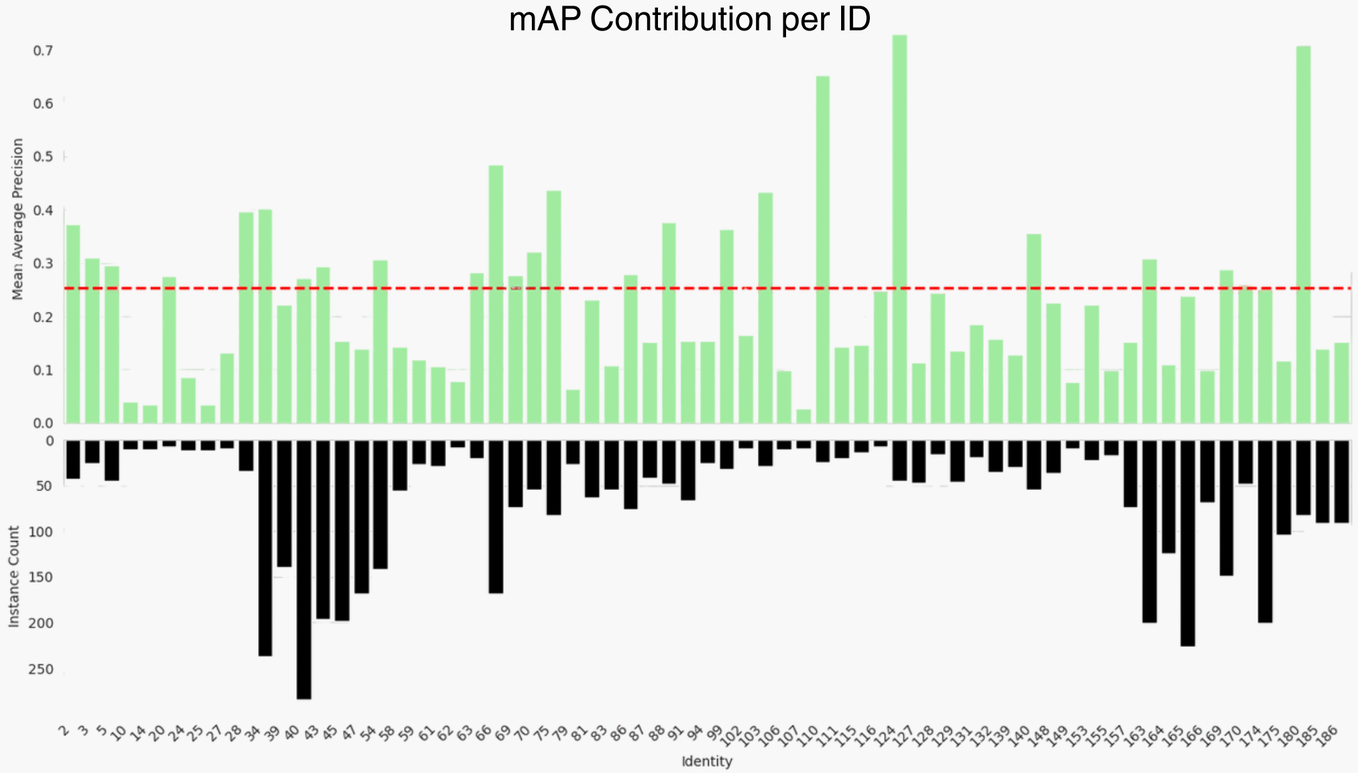
INFERÈNCIA: CONJUNT DE VALIDACIÓ

Dataset: Antic Dataset - Crops processats manualment
Nombre d'IDs: 176

Per què la diferència en les corves de mAP i Rank-1?

- Confusion Matrix → Patró a la diagonal
- Contribució d'APs al mAP → Identitats amb alt AP poc representades



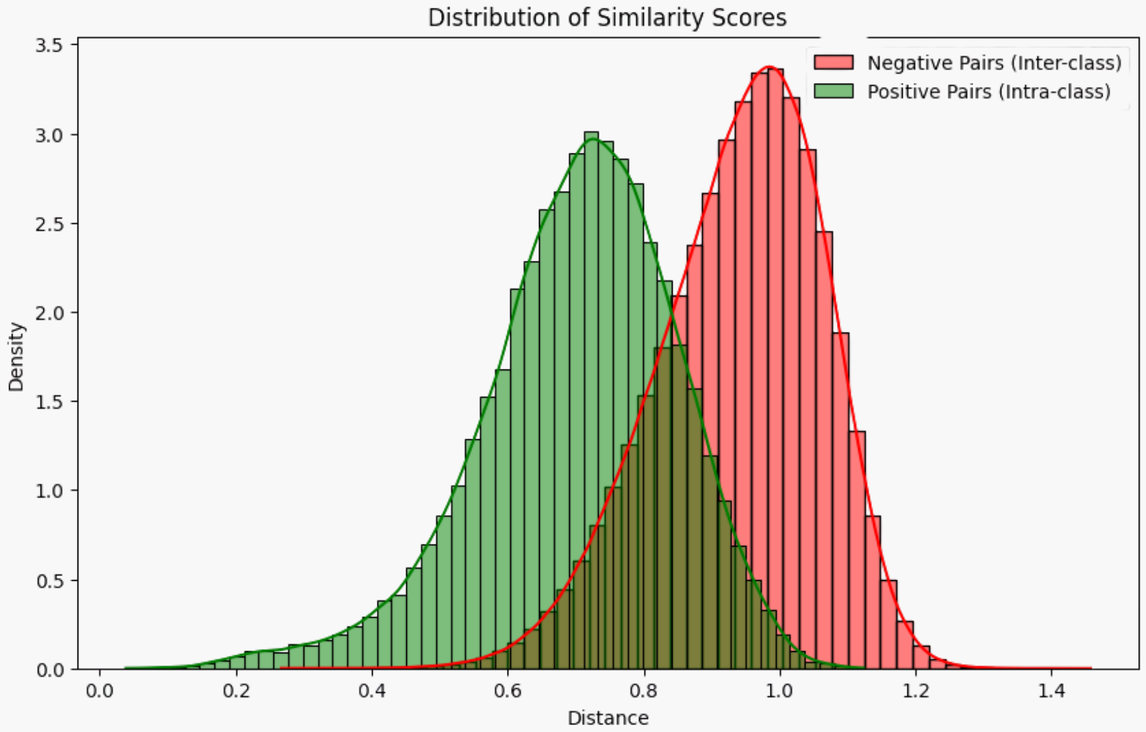


RESULTATS

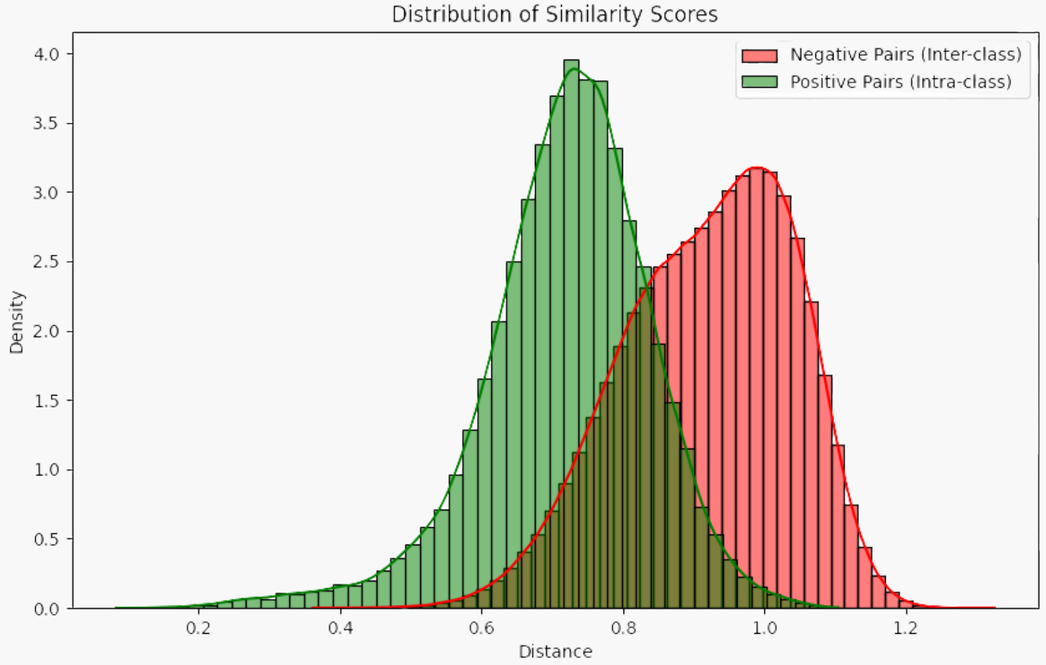
INFERÈNCIA: CONJUNT DE VALIDACIÓ

Dataset: Antic Dataset - Crops processats manualment
Nombre d'IDs: 176

BoT



RotTrans



RESULTATS

INFERÈNCIA: CONJUNT DE VALIDACIÓ

Dataset: Antic Dataset - Crops processats manualment
Nombre d'IDs: 176

BoT



RotTrans



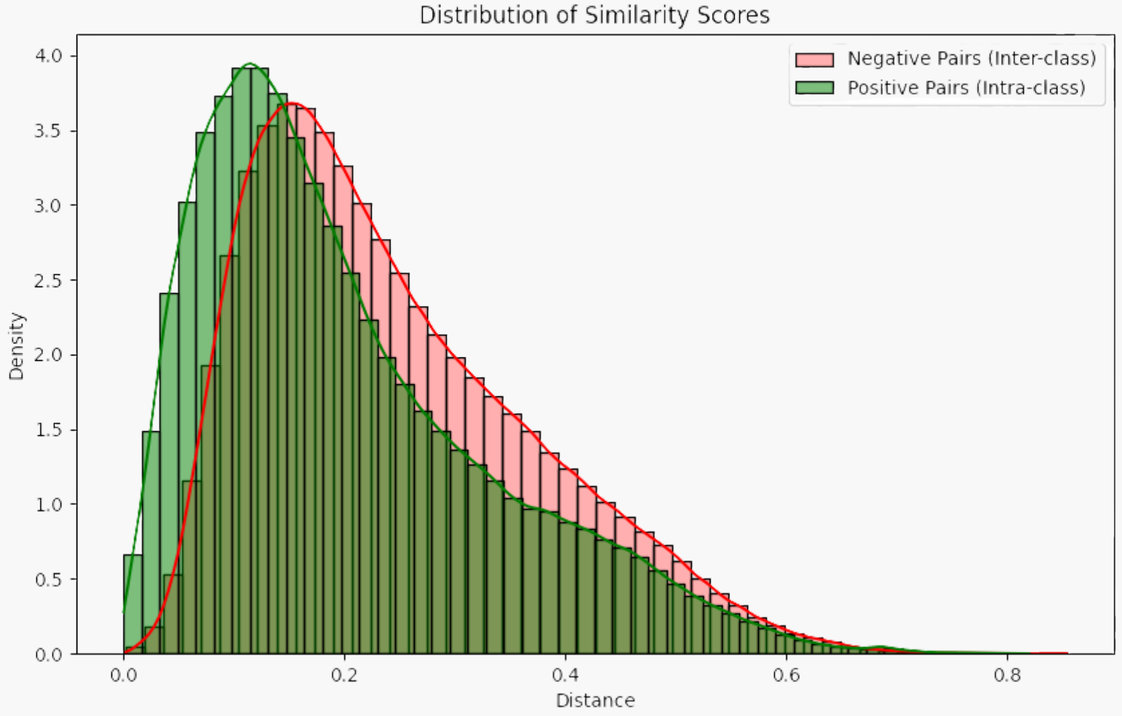
RESULTATS

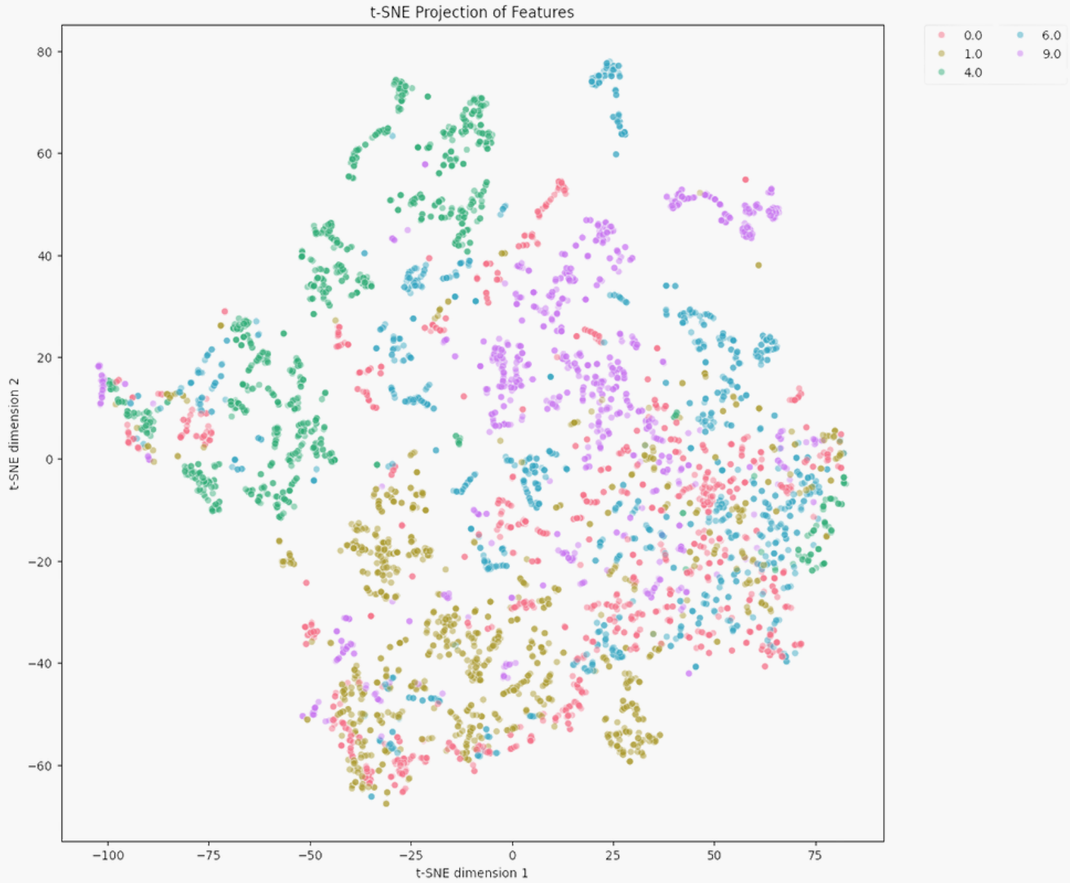
INFERÈNCIA: DATASET DE TEST

Dataset: Test - Seqüència annotada
Nombre d'IDs: 10

Associació d'identitats aleatòria

- mAP = 10.4%
- Rank-1 = 11.6%



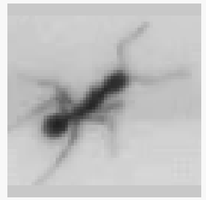
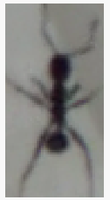


CONCLUSIONS

⇒ Millora en el model de re-identificació.

Model	*Backbone*	*Hyperparameter Config*	*Rank-1*	*Rank-5*	*mAP*	*Time*
BoT	**ResNet-50**	**Default Setup**	**72.6**	**87.3**	**28.6**	**00:20h**
RotTrans	**Small-Patch ViT**	**RotTrans Paper**	**75.5**	**86.1**	**25.3**	**03:15h**

⇒ Overfitting al model de Re-ID → Expectativa: Entrenar amb més classes pot millorar la generalització i, per tant, el rendiment

 > 

⇒ El dataset generat en aquest projecte necessita refinament. Les deteccions automàtiques es veuen superades, en quant a qualitat, per les deteccions fetes manualment.

CONCLUSIONS

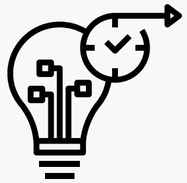
LINIES DE TREBALL FUTUR



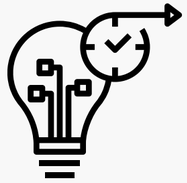
Millora en la qualitat de les dades



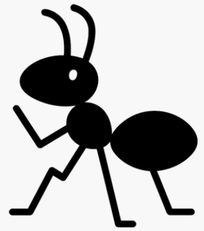
Cerca exhaustiva d’hiperparàmetres i proves amb diferents arquitectures



Integració amb el tracker i anàlisis de rendiment basat en ID Switches



Revisió de l’Estat de l’Art



Moltes gràcies per la vostra atenció!